

Proj1: 数据的捕获与构建

1 Step1: 领域选择与目标定义

1.1 领域选择

选定领域: 电商交易

领域说明: 选取真实的电商平台交易数据。该领域数据维度丰富, 包含时间戳、地理位置、价格、评分等多种数据类型。

关键实体集: 至少包含 4 个核心实体, 符合复杂性要求:

1. **Customer (客户)**: 包含客户ID、所在城市、州等。
2. **Product (商品)**: 包含商品ID、类别、尺寸、重量等。
3. **Order (订单)**: 包含订单ID、购买时间、物流状态、预计送达时间等。
4. **Seller (卖家)**: 包含卖家ID、所在地等。

1.2 数据源调研


数据来源: Kaggle开源数据集 - Brazilian E-Commerce Public Dataset by Olist

数据源链接: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

数据规模与维度:

- **规模:** 包含超过 90,000 条真实的匿名交易记录。
- **维度:** 数据以多张 CSV 表格形式提供, 天然需要进行外键关联。包含数值型 (价格、运费、长宽高)、日期型 (下单时间、发货时间、送达时间) 以及文本型 (商品类目、用户评价)。

数据源文件的关系如下:



1.3 提出分析目标

1. 物流时效与客户满意度关联分析：分析 2017-2018 年已送达订单中，实际送达时间晚于预计送达时间的订单，其订单级平均评分是否比按时送达订单低 1 分以上？
 - **【动词】**：分析
 - **【具体指标】**：订单级平均评分
 - **【比较/条件】**：实际送达时间晚于预计送达时间的订单，对比按时送达订单，评分差异是否超过 1 分
 - **【时间范围/细分领域】**：2017-2018 年已送达电商订单
2. 品类消费与复购行为差异分析：对比 2017-2018 年购买过家居家装类商品的客户与购买过美妆个护类商品的客户，其平均订单总金额与复购率是否存在明显差异？
 - **【动词】**：对比
 - **【具体指标】**：平均订单总金额、复购率
 - **【比较/条件】**：家居家装类客户对比美妆个护类客户
 - **【时间范围/细分领域】**：2017-2018 年电商客户消费行为
 - **【补充】**：在数据中，家居家装类包括 `moveis_decoracao`、`moveis_quarto`、`moveis_sala`、`cama_mesa_banho`、`utilidades_domesticas`、`eletrodomesticos`；美妆个护类包括 `beleza_saude`、`perfumaria`。复购率定义为统计期内下单数大于等于 2 的客户占比
3. 季度运费成本趋势分析：侦测 2017 年已送达订单中，第四季度订单的平均运费占订单商品总价比例是否比前三个季度更高。
 - **【动词】**：侦测
 - **【具体指标】**：平均运费占订单商品总价比例
 - **【比较/条件】**：第四季度订单对比前三个季度订单
 - **【时间范围/细分领域】**：2017 年已送达电商订单